

호서대학교 대학원

융합공학과

박사학위 논문 방어 발표

2026. 4. 30.

박사학위 논문

# 근위 정책 최적화 기반 적응형 동적 가중치 학습을 통한 Triple-Hybrid RAG 프레임워크의 성능 최적화 연구

Performance Optimization of Triple-Hybrid RAG Framework  
via Proximal Policy Optimization-based Learned Dynamic Weighting

발표자: 신동욱 (Shin Dong-wook)

지도교수: 문남미 (Prof. Nammee Moon)

# 발표 목차

Agenda

Part A

## Opening

연구 한눈에 보기 · 핵심 결과 요약

Part B

## 문제와 방법

Triple-Hybrid RAG ·  $\alpha \cdot \beta \cdot \gamma$  가중치 문제 · R-DWA 와 L-DWA

Part C

## 결과

5,000 QA 정량 비교 · Oracle 초과 · Conditional 개선

Part D

## 결론

기여 · 한계 · 향후 연구 방향

발표 시간: 약 18분 · 슬라이드 26장 + Appendix

# 한 문장 요약

Research in One Sentence

Triple-Hybrid RAG 에서 Vector · Graph · Ontology 세 지식 소스의  
가중치 결정을 PPO 로 학습한 연속 정책 (L-DWA) 이 이산 격자 Oracle  
상한을 미세하게 초과하는 지점에 도달하였다.

## ① Oracle 초과

L-DWA 3-seed 평균 F1\_strict 0.562  
> 이산 격자 Oracle 0.554 (+0.8%p)  
네 개 F1 지표 모두에서 확인  
연속 Dirichlet 평균이 격자 바깥 활용

## ② Conditional +36.7%

조건부 질의 (n=1,250) 에서  
R-DWA 0.223 → L-DWA 0.304  
Oracle (0.290) 마저 초과  
유형 내 미세 구분을 학습이 포착

## ③ 학습 비용 -85%

오프라인 보상 캐시 (330K, 16.8MB)  
로 학습 중 LLM 호출 0 회  
\$288 → \$33 · 3-seed 5시간  
개인 연구자 수준 재현 가능

# 배경 — RAG 란 무엇인가

Background · Retrieval-Augmented Generation

대형 언어모델 (LLM) 은 내부 지식만으로 답하면

- ① 환각 (없는 사실을 지어냄),
- ② 최신성 부족,
- ③ 출처 불명 문제가 발생한다.

RAG 는 답을 만들기 전에 먼저 관련 문서를 검색하여 LLM 에 참고 맥락으로 제공하는 기법이다.

본 논문의 관심은 ② Retrieval 단계. 특히 Vector · Graph · Ontology 세 이질적 소스를 동시에 사용하는 Triple-Hybrid 구조에서 각 소스의 가중치 ( $\alpha$ ,  $\beta$ ,  $\gamma$ ) 를 어떻게 정할 것인가가 연구 질문이다.

## ① 질의 (Query)

사용자 질문

## ② Retrieval (검색)

지식 소스에서 관련 정보 추출

## ③ Generation (응답)

LLM 이 맥락을 바탕으로 응답

# Triple-Hybrid — 세 지식 소스

Three Heterogeneous Knowledge Sources

## Vector 검색

문장 임베딩 유사도

FAISS, top-k=3

강점:

- 의미 기반 매칭
- 어휘 변동에 유연

약점:

- 정확한 관계 추론 어려움

## Graph 검색

엔티티-관계 BFS

NetworkX, depth=3

강점:

- 멀티홉 관계 질의
- 소속·참여 정보

약점:

- 유사 표현에 취약

## Ontology 추론

Owlready2 + HermiT

클래스·속성 추론

강점:

- 조건부 제약 (나이·자격)
- 논리적 만족성

약점:

- 스키마에 의존

세 소스는 서로 강점이 다름 → 질의마다 적절한 비율로 섞어야 함.

# $\alpha \cdot \beta \cdot \gamma$ — 가중치 문제

The Weighting Problem

## 세 소스의 기여도를 $\alpha \cdot \beta \cdot \gamma$ 로 표기, 합 = 1 제약

→  $(\alpha, \beta, \gamma)$  는  $\Delta^3$  삼각형 안의 한 점


예시:

- $(0.6, 0.2, 0.2)$  — Vector 중심
- $(0.2, 0.6, 0.2)$  — Graph 중심
- $(0.2, 0.2, 0.6)$  — Ontology 중심
- $(1/3, 1/3, 1/3)$  — 균등

핵심 어려움 — 질의마다 최적의 점이 다름.

- 「최재원 교수의 소속 학과는?» → Vector 중심
- 「55세 이하 소속 교수는?» → Ontology 중심
- 「배 포함 프로젝트 참여 학과는?» → Graph 중심

Figure 4-1. R-DWA 규칙 기반 점 vs Oracle 평균 ( $\Delta^3$  simplex)  
— R-DWA의 대각선 배치가 실제 보상 지형(Ontology 지배적) 과 정렬되지 않음



# 선행 연구 — R-DWA (규칙 기반)

Prior Work · Rule-based Dynamic Weighting

## Shin & Moon (2025, JKSCI) — 2단계 규칙

### Stage 1-2. 유형별 기본 가중치 (Table 4-1)

| 유형          | $\alpha$ | $\beta$ | $\gamma$ |
|-------------|----------|---------|----------|
| simple      | 0.6      | 0.2     | 0.2      |
| multi_hop   | 0.2      | 0.6     | 0.2      |
| conditional | 0.2      | 0.2     | 0.6      |

+ 밀도 신호  $s_r, s_c$  로 미세 조정 ( $\lambda = 0.3$ )

## R-DWA 의 네 가지 구조적 한계

- ① 도메인 편향된 기본 가중치  
— Oracle 실측은 Ontology 지배적
- ② 단일  $\lambda = 0.3$  하이퍼파라미터  
— 질의별 특성 미반영
- ③ 유형 내 미세 구분 부재  
— 같은 conditional 도 성격 다양
- ④ 도메인 이전 불가  
— HotpotQA F1 0.097 < Vector-only 0.102

→ 본 논문은 이 네 한계를 정면으로 다루기 위해 규칙 표를 학습된 신경망으로 대체한다.

# 제안 — L-DWA (MDP 공식화)

Proposed · Learned DWA as 1-step MDP

## 가중치 결정을 Markov Decision Process 로 환원 — RAG 맥락에서 최초 사례

### State (18-dim)

- 질의 메타 (길이·엔티티·제약)
- Intent logits (3-dim)
- 밀도 신호 ( $s_e, s_r, s_c$ )
- Retrieval 점수 통계량

### Action ( $\Delta^3$ )

- $(\alpha, \beta, \gamma) \cdot \text{합} = 1$
- 연속 simplex
- Dirichlet 분포에서 샘플링

### Reward (scalar)

$$R = 0.5 \cdot F1 + 0.3 \cdot EM + 0.2 \cdot \text{Faith} - 0.1 \cdot \max(0, \text{latency} - 5)$$


에피소드 길이 = 1 — 가중치를 한 번 내면 retrieval·generation 이 일어나고 즉시 보상이 결정되므로 다단계 transition 이 없음. 이 단순화가 학습을 극히 안정적으로 만들고, 오프라인 보상 캐시 아이디어의 전제가 됨.



# 신경망 구조 — Actor-Critic

Network Architecture · 5,636 parameters

Figure 5-1. Actor-Critic network architecture (shared backbone + actor head + critic head)



## 구성 요소

공유 백본:  
 $18 \rightarrow 64 \rightarrow 64$  (Tanh)

Actor head:  
 $64 \rightarrow 3$  (Dirichlet  $\alpha_i$ )

Critic head:  
 $64 \rightarrow 1$  ( $V(s)$ )


총 파라미터 = 5,636  
(스마트폰 수준)

# 학습 — PPO (Proximal Policy Optimization)

Training with PPO

## 학습 알고리즘

- OpenAI 2017, ChatGPT RLHF 에도 사용
- clip ratio = 0.2 (정책 업데이트 폭 제한)
- GAE  $\lambda = 0.95$
- Entropy coef = 0.01 (탐색 유지)
- Total episodes = 10,000
- 3 random seeds: 42, 123, 999



3-seed 표준편차 < 1% — 학습 자체의 재현성 확보.

# 오프라인 보상 캐시 — 비용 병목 해소

Offline Reward Cache

## 문제: Naive PPO 는 매 에피소드 LLM 호출 필요

- 10,000 ep × 3 seed × 32 rollout  
= 약 1M LLM 호출
- gpt-4o-mini 단가: ≈ \$288
- 개인 연구자가 반복 실험 불가

## 해결: 보상을 미리 전부 계산

- ① 5,000 질의 × 66 이산 조합 = 330,000 엔트리
- ②  $(\alpha, \beta, \gamma) \rightarrow (F1, EM, Faith, latency)$  를 SQLite 에 저장
- ③ 이후 PPO 학습은 조회만 — LLM 호출 0 회

캐시 구축 1회: \$33 · 14시간  
이후 3-seed 학습: 5시간 · \$0  
→ 총 비용 -85% 절감

## 비용 구조 비교

|            | Naive PPO   | Cache + PPO  |
|------------|-------------|--------------|
| LLM 호출     | ~1,000,000  | 330,000 (1회) |
| 학습 호출      | 10,000,000+ | 0            |
| 총 LLM 비용   | \$288       | \$33         |
| wall-clock | 50 h+       | 19 h         |
| 재학습 비용     | 매번 \$288    | 매번 \$0       |

→ 이 엔지니어링 선택이 개인 연구자 수준의  
반복 가능성을 만들어 주었다.

# 재현성 복구 — Stage-wise CORRIGENDUM

Reproducibility Recovery (S0 → S3)

선행 JKSCI 2025 의 F1 0.86 이 현 저장소로는 재현 불가

|    |                                                            |          |
|----|------------------------------------------------------------|----------|
| S0 | JKSCI 원 주장<br>재현 불가 (CORRIGENDUM §3)                       | F1 ~0.86 |
| S1 | `normalize_korean` 구두점 버그 수정<br>토큰 분리 오류 → +90% 상승         | F1 0.137 |
| S2 | `PROMPT_TEMPLATE_LIST` 로 gold 형식 정렬<br>프롬프트 리스트 형식 → +286% | F1 0.529 |
| S3 | `faithfulness()` 2-branch 도입<br>리스트형 엄격화 (측정 정직성)          | F1 0.529 |

본 논문은 S1+S2+S3 적용된 corrected baseline 위에서 L-DWA 의 순수 학습 기여를 측정.

# 실험 설계

Experimental Setup



## 벤치마크

합성 대학 코퍼스 (자체 구축)  
60 학과 / 577 교수 / 1,505 과목  
/ 400 프로젝트 / 2,542 문서  
Gold QA: 5,000 쌍  
(simple 2,000 / multi\_hop 1,750  
/ conditional 1,250)



## LLM · Embedding

gpt-4o-mini (2024-07-18)  
temperature = 0.0  
max\_tokens = 500  
text-embedding-3-small  
(1536-dim)  
FAISS IndexFlatIP, top-k=3



## 평가 지표

F1\_strict (엄격 토큰 F1)  
F1\_substring (부분 일치 F1)  
F1\_char (문자 3-gram F1)  
EM (Exact Match)  
Faithfulness (2-branch)  
Latency (seconds)

3 random seeds (42, 123, 999) 평균 보고 · post-CORRIGENDUM 평가기

# 전체 결과 — 정책별 비교 (5,000 QA)


Overall Comparison

| 정책             | F1_strict | F1_substring | F1_char | EM    | Faith | Latency |
|----------------|-----------|--------------|---------|-------|-------|---------|
| Vector-only    | 0.334     | 0.334        | 0.317   | 0.250 | 0.470 | 0.68s   |
| R-DWA          | 0.529     | 0.482        | 0.469   | 0.387 | 0.544 | 0.71s   |
| L-DWA (3-seed) | 0.562     | 0.507        | 0.494   | 0.388 | 0.580 | 0.76s   |
| Oracle         | 0.554     | 0.504        | 0.487   | 0.388 | 0.570 | 0.75s   |

핵심: L-DWA 3-seed 평균이 R-DWA 대비 F1\_strict +6.2%, Faithfulness +6.6%, 그리고 Oracle 0.554 를 네 F1 축 모두에서 초과. 3-seed 표준편차는 ±0.007 수준으로 극히 안정적.

# 유형별 F1 — 어디서 개선 폭이 큰가

Per-Type Breakdown



## 유형별 $F1_{strict}$

Simple (n=2000):

R-DWA 0.874

L-DWA 0.906

Oracle 0.901

Multi-hop (n=1750):

R-DWA 0.354

L-DWA 0.365

Oracle 0.380

Conditional (n=1250): ★

R-DWA 0.223

L-DWA 0.304 (+36.7%)

Oracle 0.290

# 핵심 결과 ① — 이산 Oracle 상한 초과

Key Finding 1 · Continuous Policy Exceeds Discrete Oracle

66-점 이산 격자  $\text{argmax Oracle (F1\_strict 0.554)}$  을  
학습된 연속 Dirichlet 평균이 네 개 F1 축 모두에서 미세하게 초과

| 지표           | R-DWA | Oracle | L-DWA |
|--------------|-------|--------|-------|
| F1_strict    | 0.529 | 0.554  | 0.562 |
| F1_substring | 0.482 | 0.504  | 0.507 |
| F1_char      | 0.469 | 0.487  | 0.494 |
| Faithfulness | 0.544 | 0.570  | 0.580 |

해석 — Oracle 은 66개 이산 점 중  $\text{argmax}$ . L-DWA 의 Dirichlet 평균은  
연속 공간 → 격자 바깥 지점을 활용 가능. 양적 개선이 아닌 질적 의미.



## 핵심 결과 ② — Conditional +27.8%

Key Finding 2 · Largest Per-Type Gain in Conditional (3-seed mean)

조건부 질의 (n = 1,250) 에서 가장 큰 상대 개선.  
L-DWA 3-seed 평균이 Oracle 0.290 과 사실상 동등 (이산 상한 도달).

R-DWA  
(기존 규칙 표)

0.223

고정 (0.2, 0.2, 0.6)

Oracle  
(이산 상한)

0.290

66-점 argmax

L-DWA  
(3-seed 평균)

0.285

$\pm 0.029$  (s42 0.304 / s123 0.251 / s999 0.301)

해석 — 같은 conditional 이라도 수치 제약 · 열거형 · 배타 조건이 각기 다른데,  
R-DWA 는 이들을 하나로 묶어 처리. 학습이 내부 차이를 포착.

# 통계적 방어 — Paired Bootstrap (BCa 95% CI)

Statistical Significance · 5,000 BCa Resamples · Cohen's d\_z

5,000 query-level paired bootstrap. Cache regime, F1.  
L-DWA 3 seeds 모두 R-DWA 를 통계적으로 유의하게 능가 ( $p < 1e-4$ ).


| 비교 (vs R-DWA)           | $\Delta$ | 95% CI (BCa)       | p      | Cohen's d_z | 판정 |
|-------------------------|----------|--------------------|--------|-------------|----|
| Uniform (1/3, 1/3, 1/3) | +0.0114  | [+0.0091, +0.0138] | < 1e-4 | +0.135      | ✓  |
| Vector-only             | +0.0107  | [+0.0080, +0.0132] | < 1e-4 | +0.114      | ✓  |
| L-DWA seed 42           | +0.0147  | [+0.0123, +0.0170] | < 1e-4 | +0.174      | ✓  |
| L-DWA seed 123          | +0.0143  | [+0.0120, +0.0167] | < 1e-4 | +0.173      | ✓  |
| L-DWA seed 999          | +0.0125  | [+0.0101, +0.0149] | < 1e-4 | +0.146      | ✓  |
| Oracle (per-q argmax)   | +0.0494  | [+0.0464, +0.0524] | < 1e-4 | +0.456      | ✓  |

정직한 부수 발견: Cache regime 에서 R-DWA 가 Uniform/Vector-only 에 유의하게 진다 ( $\Delta -0.011$ ,  $p < 1e-4$ ).  
→ R-DWA 의 baseline 가치는 단일 소스 회피에 있으나 균등 분배 능가는 아님 (RQ1 부정 답변).  
→ List-prompt regime 에서의 Uniform 비교는 §8 나 1순위 향후 연구로 명시.

# $\Delta^3$ 위 정책별 평균 가중치 분포

Mean Weight Positions on the 3-Simplex

Figure 6-3. DWA weight distribution on  $\Delta^3$  simplex (5,000 QA, list prompt)



## 읽는 법

R-DWA 평균 (파랑):  
(0.25, 0.45, 0.30)  
Graph 쪽 치우침

L-DWA 평균 (빨강):  
(0.25, 0.30, 0.45)  
Ontology 쪽 이동


Oracle 평균 (초록):  
(0.11, 0.16, 0.73)  
Ontology 꼭짓점 근처

정답 분포의 진짜 지형은 Ontology 지배적. R-DWA 는 이를 반영하지 못함.

# PPO 3-seed 학습 곡선

PPO Convergence across 3 Seeds


Figure 5-2. PPO L-DWA training curves — 3 seeds (42, 123, 999)



세 시드 모두  $\text{mean\_reward} \approx 0.215 \pm 0.002$  로 수렴.  
1% 미만의 표준편차 → 학습 자체의 재현 가능성 확보.

# 교차 도메인 — naive transfer 의 한계와 원인 분해

Cross-domain · Failure Decomposed into 3 Axes



## 실패의 세 층위

- ① 언어 장벽  
한국어 정규식 intent → 영어 질의 density  $\approx 0$   
→ 영어 intent 추가 시 R-DWA +38%, L-DWA +49%
- ② 도메인 어휘  
학습된 엔티티 vs HotpotQA 엔티티 상이  
→ 영어 합성 벤치마크 R-DWA 0.663  
(한국어 0.529 보다 높음)
- ③ Graph·Ontology 부재  
HotpotQA 는 그래프 구조 없음  
→ 재학습 해도 곡선 평탄  
= Triple-Hybrid 의 본질적 경계

# 이 논문의 기여 네 가지

Four Contributions

## 방법론

Triple-Hybrid RAG 의 가중치 결정을 1-step MDP 로 공식화하고 PPO 로 학습한 최초 사례

## 엔지니어링

오프라인 보상 캐시 (330K, 16.8 MB) 로 학습 비용 \$288 → \$33 (-85%).  
RL-based RAG 튜닝을 개인 연구자 수준으로 접근 가능하게

## 재현성

선행 JKSCI 2025 의 평가 코드 결함 3건 발견 · 수정 · CORRIGENDUM 공개 정정  
(구두점 처리 · 프롬프트 형식 · Faithfulness 2-branch)

## 실증

L-DWA 가 R-DWA 대비 F1\_strict +6.2%, 이산 Oracle 상한 0.554 를 0.562 로 초과.  
Conditional 유형에서 3-seed 평균 +27.8% (R-DWA 0.223 → L-DWA 0.285), Oracle 0.290 과 동등.  
Paired bootstrap 으로 L-DWA 3-seed 모두 R-DWA 유의 능가 ( $\Delta \approx +0.014$ ,  $p < 1e-4$ ) 검증.

# 한계 및 향후 연구 방향

Limitations & Future Work

## 솔직하게 보고하는 한계

- 한국어 단일 도메인 end-to-end 학습
- State 품질이 L-DWA 상한 결정  
(영어 state 미구분 → R-DWA 수준)
- EM 구조적 문제 — list prompt 로 0.39 회복
- BERT intent classifier 미학습
- 교차 도메인 naive transfer -30~35%

## 향후 연구 방향

- 다국어 state feature 설계
- 도메인별 fine-tuning 레시피 체계화
- Reward 재설계 (EM 가중치 재분배)
- Joint multi-domain training
- 더 큰 Actor-Critic 의 스케일링 효과
- 선행 저장소와 평가기 통일

# 연구 과정에서 얻은 두 교훈

Two Lessons Learned

## ① 평가 코드를 다시 들여다본 경험

마무리 단계에서 F1 수치가 기대보다 낮다는 인상을 받아 `normalize_korean` 을 역추적인 끝에, 쉼표와 마침표가 토큰화 이전에 제거되지 않는 작은 버그를 발견. 이를 바로잡고 나서야 L-DWA 의 Oracle 대비 위치가 제대로 드러남.

→ 실험 결과가 직관과 어긋날 때 평가 코드부터 다시 읽어 보는 습관의 중요성.

## ② 기대와 다르게 나온 결과를 어떻게 다룰지

교차 도메인 실험이 30~35% 저하로 나오자 한 문단 "한계" 로 넘기고 싶은 유혹이 있었음. 그러나 원인을 언어 · 도메인 · 아키텍처로 나누어 각각 별도 실험으로 확인해 보는 편이 오히려 더 명확한 결론을 냄.

→ 부정적 결과를 빨리 결론짓지 않는 쪽이 장기적으로 나은 서사를 만든다.



# 감사합니다

Thank you · 질의응답 (Q&A)

## 공개 자원

GitHub: [github.com/sdw1621/triple-rag-phd](https://github.com/sdw1621/triple-rag-phd)

Dashboard: [triple-rag-phd.streamlit.app](https://triple-rag-phd.streamlit.app)

CORRIGENDUM: [github.com/sdw1621/hybrid-rag-comparsion/blob/main/CORRIGENDUM.md](https://github.com/sdw1621/hybrid-rag-comparsion/blob/main/CORRIGENDUM.md)

신동욱 · 호서대학교 대학원 융합공학과 · 2026

# Appendix A — PPO Hyperparameters

Table 5-4 reproduction

|               |        |                     |              |
|---------------|--------|---------------------|--------------|
| learning_rate | 3.0e-4 | total_episodes      | 10,000       |
| gae_lambda    | 0.95   | rollout_per_episode | 32           |
| clip_ratio    | 0.2    | update_epochs       | 4            |
| value_coef    | 0.5    | minibatch_size      | 8            |
| entropy_coef  | 0.01   | gamma               | 0.99         |
| max_grad_norm | 0.5    | seeds               | 42, 123, 999 |

# Appendix B — Case Studies CS-1 ~ CS-7 요약

Qualitative case summaries

|      |                       |                                                  |
|------|-----------------------|--------------------------------------------------|
| CS-1 | Simple 정책 수렴          | 세 정책 모두 F1=1.0 (최재원 교수 소속 학과)                    |
| CS-2 | Multi-hop 부분 회수       | R-DWA/L-DWA 동일 1/2 엔티티, Oracle 2/2               |
| CS-3 | Conditional 개선과 한계    | 개별 실패지만 유형 집계 +27.8% (3-seed mean, Oracle 동등)    |
| CS-4 | Faithfulness 2-branch | Sentence 1.0 (과대) vs List 0.5 (환각 노출)            |
| CS-5 | Retrieval 한계          | Oracle 조차 12개 중 2개만 — 컨텍스트 상한                    |
| CS-6 | 교차 도메인 퇴행             | 영어 질의 → density 0 → Vector-only 이하               |
| CS-7 | List 프롬프트 효과          | F1_strict 0.137 → 0.529 (×3.86), 평균 latency -50% |