호서대학교 대학원
융합공학과

박사학위 논문

근위 정책 최적화 기반 적응형 동적 가중치 학습을 통한 Triple-Hybrid RAG 프레임워크의 성능 최적화 연구

Performance Optimization of Triple-Hybrid RAG Framework
via Proximal Policy Optimization-based Learned Dynamic Weighting

발표자 : 신동욱 (Shin Dong-wook)

지도교수 : 문남미 (Prof. Nammee Moon)

박사학위 논문 방어 발표

2026. 4. 30.

발표 목차

Agenda

Part A
Opening
연구 한눈에 보기 · 핵심 결과 요약

Part B
문제와 방법
Triple-Hybrid RAG · α·β·γ 가중치 문제 · R-DWA 와 L-DWA

Part C
결과
5,000 QA 정량 비교 · Oracle 초과 · Conditional 개선

Part D
결론
기여 · 한계 · 향후 연구 방향

발표 시간 : 약 18 분 · 슬라이드 26 장 + Appendix

한 문장 요약

Research in One Sentence

Triple-Hybrid RAG 에서 Vector · Graph · Ontology 세 지식 소스의 가중치 결정을 PPO 로 학습한 연속 정책 (L-DWA) 이 이산 격자 Oracle 상한을 미세하게 초과하는 지점에 도달하였다 .

① Oracle 초과

L-DWA 3-seed 평균 F1_strict 0.562
> 이산 격자 Oracle 0.554 (+0.8%p)
네 개 F1 지표 모두에서 확인
연속 Dirichlet 평균이 격자 바깥 활용

② Conditional +36.7%

조건부 질의 (n=1,250) 에서
R-DWA 0.223 → L-DWA 0.304
Oracle (0.290) 마저 초과
유형 내 미세 구분을 학습이 포착

③ 학습 비용 – 85%

오프라인 보상 캐시 (330K, 16.8MB)
로 학습 중 LLM 호출 0 회
$288 → $33 · 3-seed 5 시간
개인 연구자 수준 재현 가능

배경 — RAG 란 무엇인가

Background · Retrieval-Augmented Generation

대형 언어모델 (LLM) 은 내부 지식만으로 답하면
① 환각 (없는 사실을 지어냄),
② 최신성 부족 ,
③ 출처 불명 문제가 발생한다 .

RAG 는 답을 만들기 전에 먼저 관련 문서를 검색하여
LLM 에 참고 맥락으로 제공하는 기법이다 .

① 질의 (Query)
사용자 질문

② Retrieval (검색)
지식 소스에서 관련 정보 추출

③ Generation (응답)
LLM 이 맥락을 바탕으로 응답

본 논문의 관심은 ② Retrieval 단계 . 특히 Vector · Graph · Ontology 세 이질적 소스를 동시에 사용하는 Triple-Hybrid 구조에서 각 소스의 가중치 (α, β, γ) 를 어떻게 정할 것인가가 연구 질문이다 .

Triple-Hybrid — 세 지식 소스

Three Heterogeneous Knowledge Sources

☒ Vector 검색

문장 임베딩 유사도
FAISS, top-k=3
강점 :
- 의미 기반 매칭
- 어휘 변동에 유연

약점 :
- 정확한 관계 추론 어려움

☒ Graph 검색

엔티티 - 관계 BFS
NetworkX, depth=3
강점 :
- 멀티홉 관계 질의
- 소속 · 참여 정보

약점 :
- 유사 표현에 취약

☒ Ontology 추론

Owlready2 + HermiT
클래스 · 속성 추론
강점 :
- 조건부 제약 (나이 · 자격)
- 논리적 만족성

약점 :
- 스키마에 의존

세 소스는 서로 강점이 다름 → 질의마다 적절한 비율로 섞어야 함 .

α·β·γ — 가중치 문제

The Weighting Problem

세 소스의 기여도를 α·β·γ 로 표기, 합 = 1 제약

→ (α, β, γ) 는 Δ^3 삼각형 안의 한 점

예시 :
- (0.6, 0.2, 0.2) — Vector 중심
- (0.2, 0.6, 0.2) — Graph 중심
- (0.2, 0.2, 0.6) — Ontology 중심
- (1/3, 1/3, 1/3) — 균등

핵심 어려움 — 질의마다 최적의 점이 다름 .
- 「최재원 교수의 소속 학과는 ? 」 → Vector 중심
- 「 55 세 이하 소속 교수는 ? 」 → Ontology 중심
- 「배 포함 프로젝트 참여 학과는 ? 」 → Graph 중심

Figure 4-1. R-DWA 규칙 기반 점 vs Oracle 평균 (Δ^3 simplex)
— R-DWA의 대각선 배치가 실제 보상 지형(Ontology 지배적) 과 정렬되지 않음

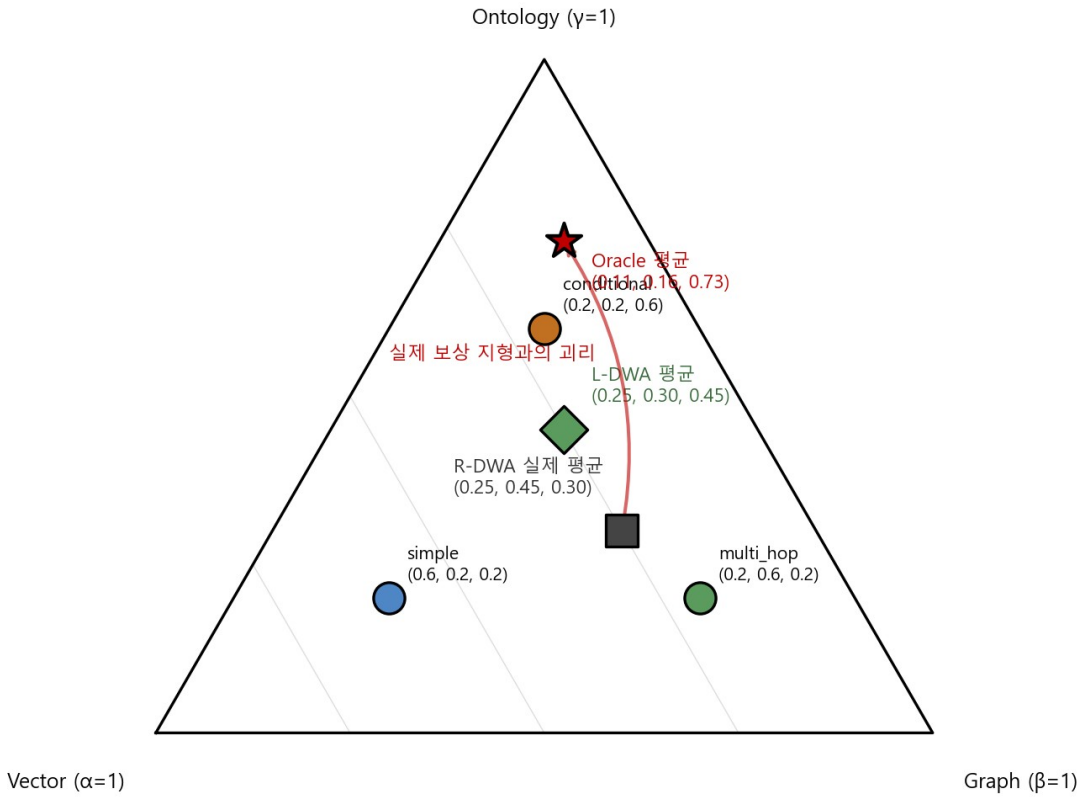

선행 연구 — R-DWA (규칙 기반)

Prior Work · Rule-based Dynamic Weighting

Shin & Moon (2025, JKSCI) — 2 단계 규칙

Stage 1-2. 유형별 기본 가중치 (Table 4-1)

유형	α	β	γ
simple	0.6	0.2	0.2
multi_hop	0.2	0.6	0.2
conditional	0.2	0.2	0.6

+ 밀도 신호 s_r, s_c 로 미세 조정 (λ = 0.3)

R-DWA 의 네 가지 구조적 한계

① 도메인 편향된 기본 가중치
— Oracle 실측은 Ontology 지배적

② 단일 λ = 0.3 하이퍼파라미터
— 질의별 특성 미반영

③ 유형 내 미세 구분 부재
— 같은 conditional 도 성격 다양

④ 도메인 이전 불가
— HotpotQA F1 0.097 < Vector-only 0.102

→ 본 논문은 이 네 한계를 정면으로 다루기 위해 규칙 표를 학습된 신경망으로 대체한다 .

제안 — L-DWA (MDP 공식화)

Proposed · Learned DWA as 1-step MDP

가중치 결정을 Markov Decision Process 로 환원 — RAG 맥락에서 최초 사례

State (18-dim)

- 질의 메타 (길이 · 엔티티 · 제약)
- Intent logits (3-dim)
- 밀도 신호 (s_e, s_r, s_c)
- Retrieval 점수 통계량

Action (Δ^3)

- (α, β, γ) · 합 = 1
- 연속 simplex
- Dirichlet 분포에서 샘플링

Reward (scalar)

$R = 0.5 \cdot F1 + 0.3 \cdot EM$
$+ 0.2 \cdot Faith$
$- 0.1 \cdot \max(0, latency-5)$

에피소드 길이 = 1 — 가중치를 한 번 내면 retrieval·generation 이 일어나고
즉시 보상이 결정되므로 다단계 transition 이 없음 . 이 단순화가 학습을
극히 안정적으로 만들고 , 오프라인 보상 캐시 아이디어의 전제가 됨 .

신경망 구조 — Actor-Critic

Network Architecture · 5,636 parameters

Figure 5-1. Actor-Critic network architecture (shared backbone + actor head + critic head)

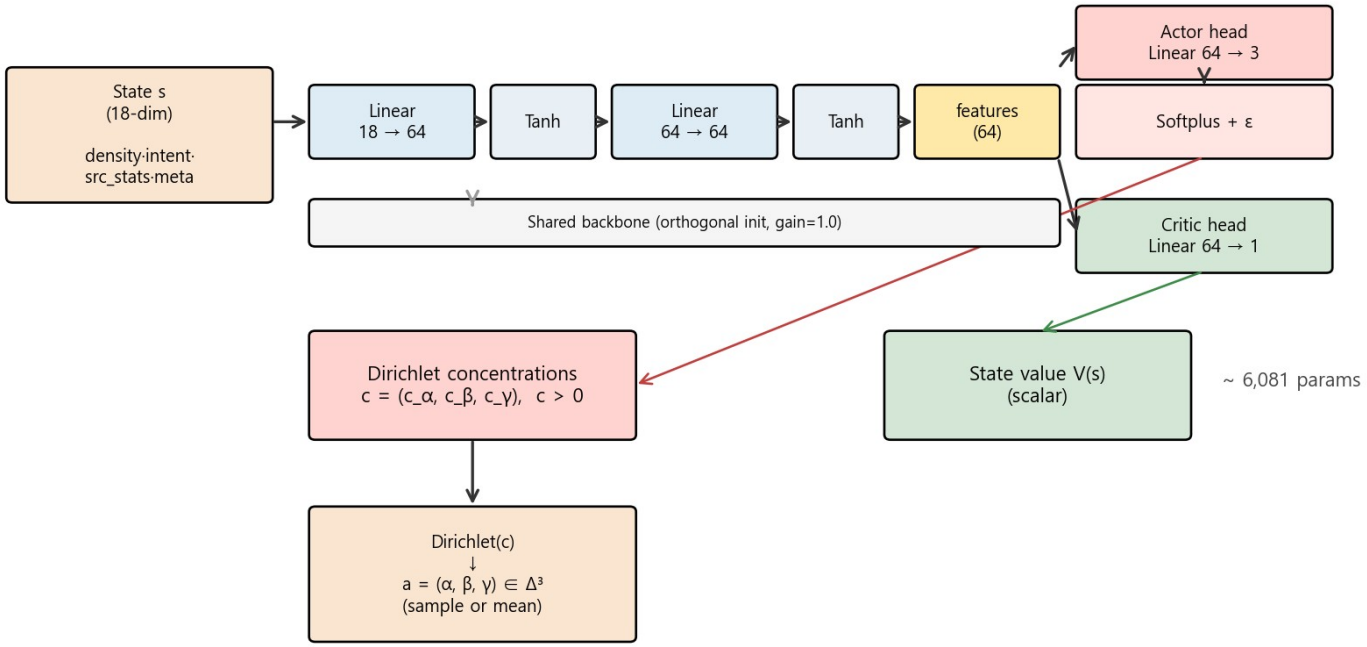

구성 요소

공유 백본 :
18 → 64 → 64 (Tanh)

Actor head:
64 → 3 (Dirichlet α_i)

Critic head:
64 → 1 (V(s))

총 파라미터 = 5,636
(스마트폰 수준)

학습 — PPO (Proximal Policy Optimization)

Training with PPO

학습 알고리즘

- OpenAI 2017, ChatGPT RLHF 에도 사용
- clip ratio = 0.2 (정책 업데이트 폭 제한)
- GAE λ = 0.95
- Entropy coef = 0.01 (탐색 유지)
- Total episodes = 10,000
- 3 random seeds: 42, 123, 999

Figure 5-2. PPO L-DWA training curves — 3 seeds (42, 123, 999)

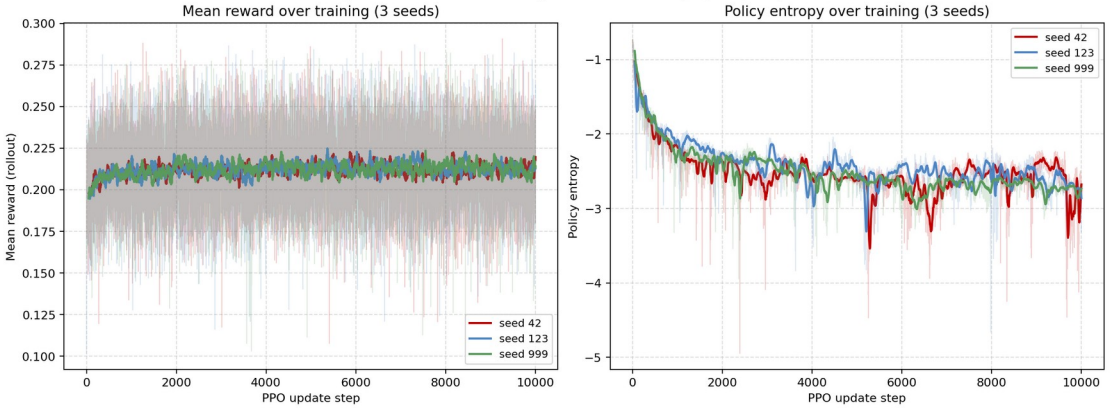

3-seed 표준편차 < 1% — 학습 자체의 재현성 확보 .

오프라인 보상 캐시 — 비용 병목 해소

Offline Reward Cache

문제 : Naive PPO 는 매 에피소드 LLM 호출 필요

- 10,000 ep × 3 seed × 32 rollout
  = 약 1M LLM 호출
- gpt-4o-mini 단가 : ≈ $288
- 개인 연구자가 반복 실험 불가

해결 : 보상을 미리 전부 계산

① 5,000 질의 × 66 이산 조합 = 330,000 엔트리
② (α, β, γ) → (F1, EM, Faith, latency) 를 SQLite 에 저장
③ 이후 PPO 학습은 조회만 — LLM 호출 0 회

캐시 구축 1 회 : $33 · 14 시간
이후 3-seed 학습 : 5 시간 · $0
→ 총 비용 – 85% 절감

비용 구조 비교

	Naive PPO	Cache + PPO
LLM 호출	~1,000,000	330,000 (1 회)
학습 호출	10,000,000+	0
총 LLM 비용	$288	$33
wall-clock	50 h+	19 h
재학습 비용	매번 $288	매번 $0

→ 이 엔지니어링 선택이 개인 연구자 수준의 반복 가능성을 만들어 주었다 .

재현성 복구 — Stage-wise CORRIGENDUM

Reproducibility Recovery (S0 → S3)

선행 JKSCI 2025 의 F1 0.86 이 현 저장소로는 재현 불가

S0	**JKSCI 원 주장** 재현 불가 (CORRIGENDUM §3)	F1 ~0.86
S1	**`normalize_korean` 구두점 버그 수정** 토큰 분리 오류 → +90% 상승	F1 0.137
S2	**`PROMPT_TEMPLATE_LIST` 로 gold 형식 정렬** 프롬프트 리스트 형식 → +286%	F1 0.529
S3	**`faithfulness()` 2-branch 도입** 리스트형 엄격화 (측정 정직성)	F1 0.529

본 논문은 S1+S2+S3 적용된 corrected baseline 위에서 L-DWA 의 순수 학습 기여를 측정 .

실험 설계

Experimental Setup

☒ 벤치마크

합성 대학 코퍼스 (자체 구축)
60 학과 / 577 교수 / 1,505 과목
/ 400 프로젝트 / 2,542 문서
Gold QA: 5,000 쌍
(simple 2,000 / multi_hop 1,750
/ conditional 1,250)

☒ LLM · Embedding

gpt-4o-mini (2024-07-18)
temperature = 0.0
max_tokens = 500
text-embedding-3-small
(1536-dim)
FAISS IndexFlatIP, top-k=3

☒ 평가 지표

F1_strict (엄격 토큰 F1)
F1_substring (부분 일치 F1)
F1_char (문자 3-gram F1)
EM (Exact Match)
Faithfulness (2-branch)
Latency (seconds)

3 random seeds (42, 123, 999) 평균 보고 · post-CORRIGENDUM 평가기

전체 결과 — 정책별 비교 (5,000 QA)

Overall Comparison

정책	F1_strict	F1_substring	F1_char	EM	Faith	Latency
Vector-only	0.334	0.334	0.317	0.250	0.470	0.68s
R-DWA	0.529	0.482	0.469	0.387	0.544	0.71s
L-DWA (3-seed)	0.562	0.507	0.494	0.388	0.580	0.76s
Oracle	0.554	0.504	0.487	0.388	0.570	0.75s

핵심 : L-DWA 3-seed 평균이 R-DWA 대비 F1_strict +6.2%,
Faithfulness +6.6%, 그리고 Oracle 0.554 를 네 F1 축 모두에서 초과 .
3-seed 표준편차는 ±0.007 수준으로 극히 안정적 .

유형별 F1 — 어디서 개선 폭이 큰가

Per-Type Breakdown

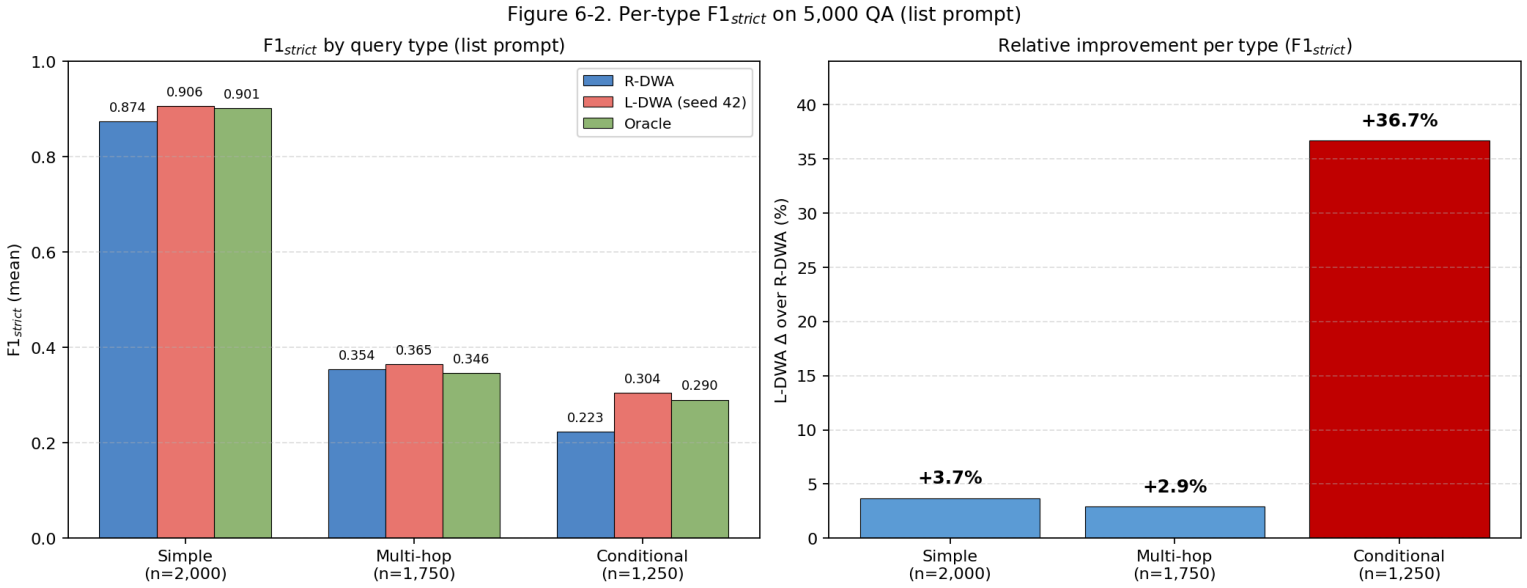

유형별 F1_strict

Simple (n=2000):
- R-DWA 0.874
- L-DWA 0.906
- Oracle 0.901

Multi-hop (n=1750):
- R-DWA 0.354
- L-DWA 0.365
- Oracle 0.380

Conditional (n=1250): ★
- R-DWA 0.223
- L-DWA 0.304 (+36.7%)
- Oracle 0.290

핵심 결과 ① — 이산 Oracle 상한 초과

Key Finding 1 · Continuous Policy Exceeds Discrete Oracle

66- 점 이산 격자 argmax Oracle (F1_strict 0.554) 을 학습된 연속 Dirichlet 평균이 네 개 F1 축 모두에서 미세하게 초과

지표	R-DWA	Oracle	L-DWA
F1_strict	0.529	0.554	**0.562**
F1_substring	0.482	0.504	**0.507**
F1_char	0.469	0.487	**0.494**
Faithfulness	0.544	0.570	**0.580**

해석 — Oracle 은 66 개 이산 점 중 argmax. L-DWA 의 Dirichlet 평균은 연속 공간 → 격자 바깥 지점을 활용 가능 . 양적 개선이 아닌 질적 의미 .

핵심 결과 ② — Conditional +36.7%

Key Finding 2 · Largest Per-Type Gain in Conditional

조건부 질의 (n = 1,250) 에서 가장 큰 상대 개선 .
L-DWA 가 Oracle 마저 근소하게 초과 .

R-DWA (기존 규칙 표)	Oracle (이산 상한)	L-DWA (본 연구)
0.223	0.290	0.304
고정 (0.2, 0.2, 0.6)	66- 점 argmax	질의별 동적 가중치

해석 — 같은 conditional 이라도 수치 제약 · 열거형 · 배타 조건이 각기 다른데 ,
R-DWA 는 이들을 하나로 묶어 처리 . 학습이 내부 차이를 포착 .

Δ^3 위 정책별 평균 가중치 분포

Mean Weight Positions on the 3-Simplex

Figure 6-3. DWA weight distribution on Δ^3 simplex (5,000 QA, list prompt)

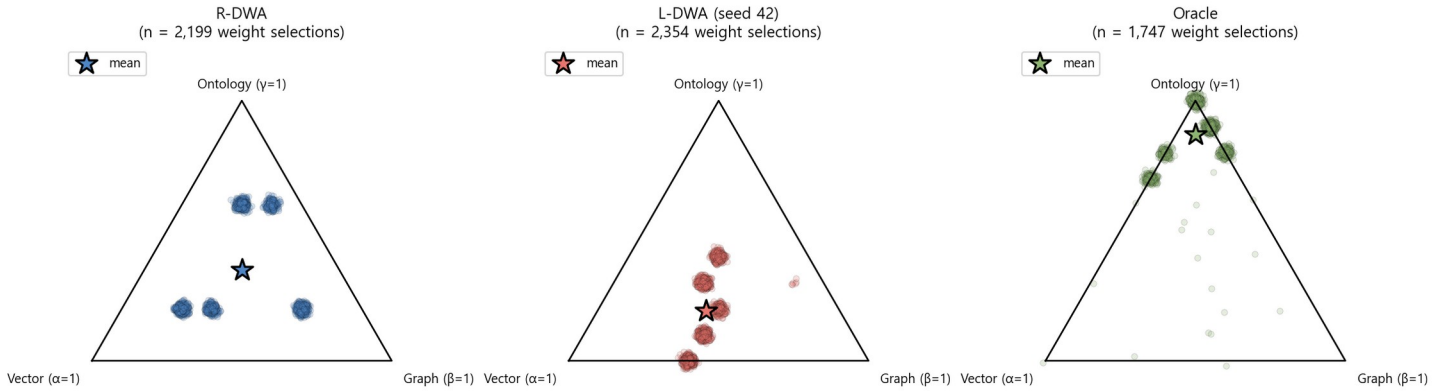

읽는 법

R-DWA 평균 (파랑):
(0.25, 0.45, 0.30)
Graph 쪽 치우침

L-DWA 평균 (빨강):
(0.25, 0.30, 0.45)
Ontology 쪽 이동

Oracle 평균 (초록):
(0.11, 0.16, 0.73)
Ontology 꼭짓점 근처

정답 분포의 진짜 지형은 Ontology 지배적 . R-DWA 는 이를 반영하지 못함 .

PPO 3-seed 학습 곡선

PPO Convergence across 3 Seeds

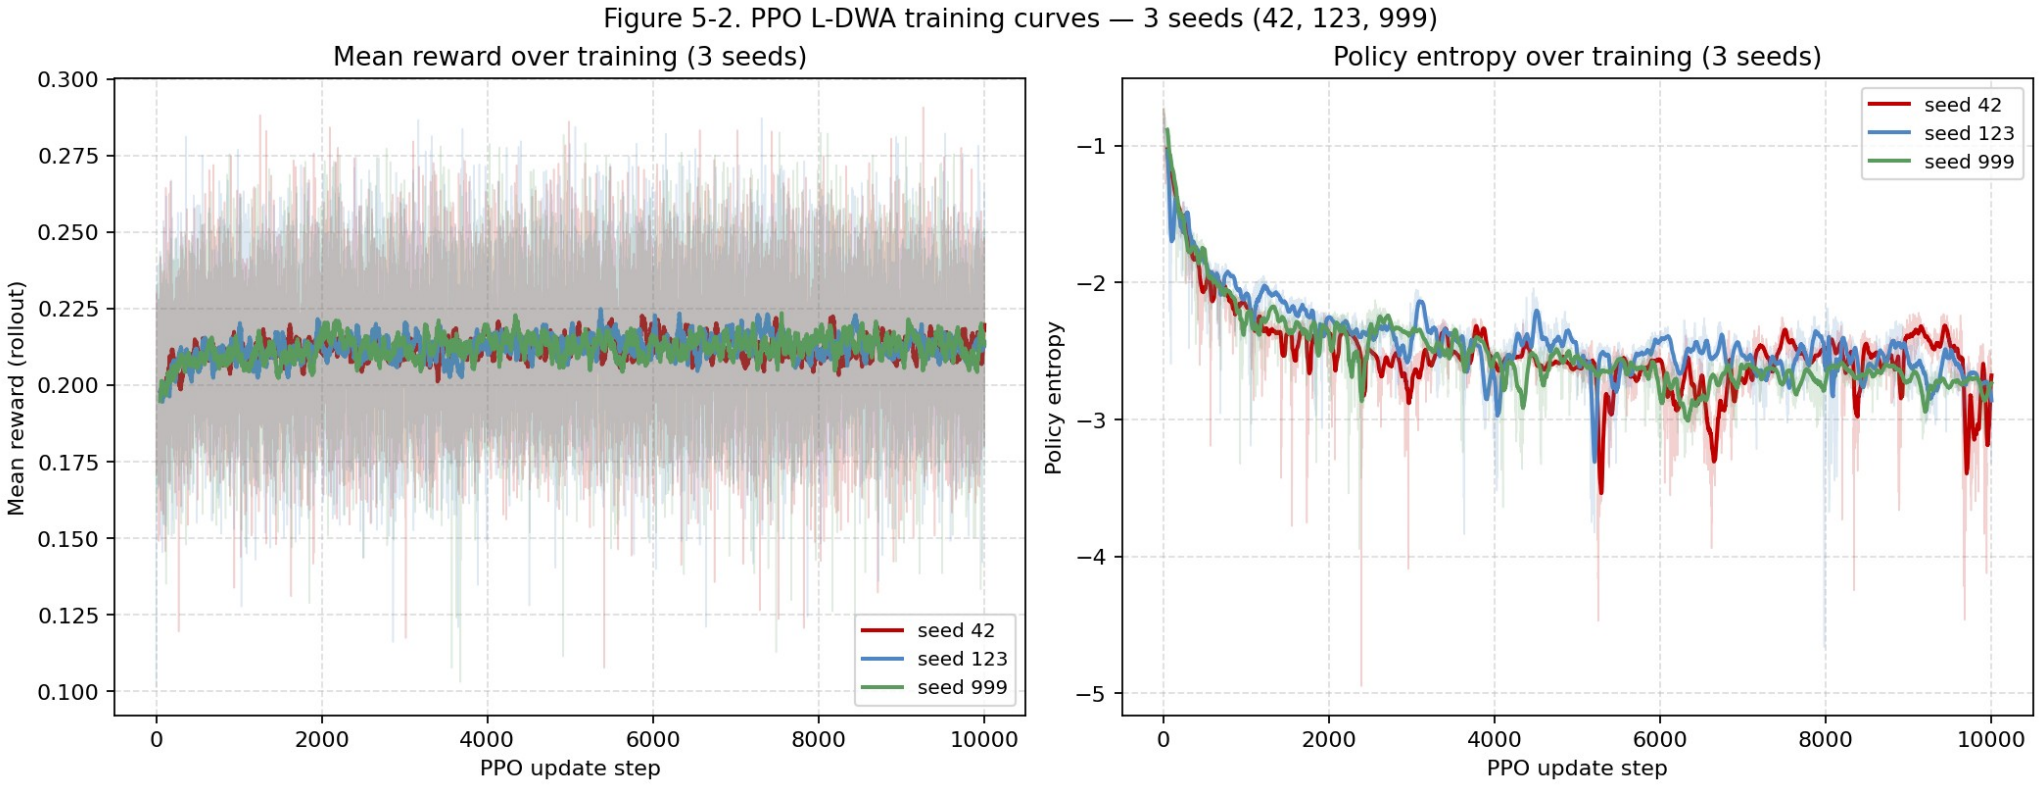

세 시드 모두 mean_reward ≈ 0.215 ± 0.002 로 수렴 .
1% 미만의 표준편차 → 학습 자체의 재현 가능성 확보 .

교차 도메인 — naive transfer 의 한계와 원인 분해

Cross-domain · Failure Decomposed into 3 Axes

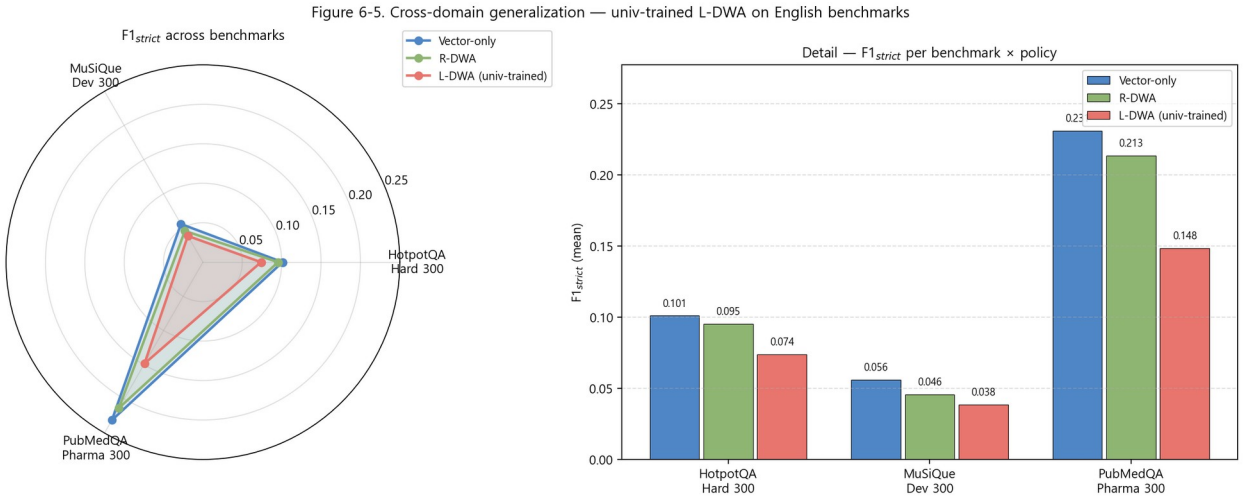

실패의 세 층위

① 언어 장벽
한국어 정규식 intent → 영어 질의 density ≈ 0
→ 영어 intent 추가 시 R-DWA +38%, L-DWA +49%

② 도메인 어휘
학습된 엔티티 vs HotpotQA 엔티티 상이
→ 영어 합성 벤치마크 R-DWA 0.663
(한국어 0.529 보다 높음)

③ Graph·Ontology 부재
HotpotQA 는 그래프 구조 없음
→ 재학습 해도 곡선 평탄
= Triple-Hybrid 의 본질적 경계

이 논문의 기여 네 가지

Four Contributions

방법론

Triple-Hybrid RAG 의 가중치 결정을 1-step MDP 로 공식화하고 PPO 로 학습한 최초 사례

엔지니어링

오프라인 보상 캐시 (330K, 16.8 MB) 로 학습 비용 $288 → $33 (−85%).
RL-based RAG 튜닝을 개인 연구자 수준으로 접근 가능하게

재현성

선행 JKSCI 2025 의 평가 코드 결함 3 건 발견 · 수정 · CORRIGENDUM 공개 정정
(구두점 처리 · 프롬프트 형식 · Faithfulness 2-branch)

실증

L-DWA 가 R-DWA 대비 F1_strict +6.2%, 이산 Oracle 상한 0.554 를 0.562 로 초과 .
Conditional 유형에서 +36.7% 의 가장 큰 상대 개선 .

한계 및 향후 연구 방향

Limitations & Future Work

솔직하게 보고하는 한계

- 한국어 단일 도메인 end-to-end 학습
- State 품질이 L-DWA 상한 결정
  (영어 state 미구분 → R-DWA 수준)
- EM 구조적 문제 — list prompt 로 0.39 회복
- BERT intent classifier 미학습
- 교차 도메인 naive transfer −30~35%

향후 연구 방향

- 다국어 state feature 설계
- 도메인별 fine-tuning 레시피 체계화
- Reward 재설계 (EM 가중치 재분배)
- Joint multi-domain training
- 더 큰 Actor-Critic 의 스케일링 효과
- 선행 저장소와 평가기 통일

연구 과정에서 얻은 두 교훈

Two Lessons Learned

① 평가 코드를 다시 들여다본 경험

마무리 단계에서 F1 수치가 기대보다 낮다는 인상을 받아 normalize_korean 을 역추적한 끝에, 쉼표와 마침표가 토큰화 이전에 제거되지 않는 작은 버그를 발견. 이를 바로잡고 나서야 L-DWA 의 Oracle 대비 위치가 제대로 드러남.

→ 실험 결과가 직관과 어긋날 때 평가 코드부터 다시 읽어 보는 습관의 중요성.

② 기대와 다르게 나온 결과를 어떻게 다룰지

교차 도메인 실험이 30~35% 저하로 나오자 한 문단 "한계" 로 넘기고 싶은 유혹이 있었음. 그러나 원인을 언어 · 도메인 · 아키텍처로 나누어 각각 별도 실험으로 확인해 보는 편이 오히려 더 명확한 결론을 냄.

→ 부정적 결과를 빨리 결론짓지 않는 쪽이 장기적으로 나은 서사를 만든다.

감사합니다

Thank you · 질의응답 (Q&A)

공개 자원

GitHub: github.com/sdw1621/triple-rag-phd
Dashboard: triple-rag-phd.streamlit.app
CORRIGENDUM: github.com/sdw1621/hybrid-rag-comparsion/blob/main/CORRIGENDUM.md

신동욱 · 호서대학교 대학원 융합공학과 · 2026

Appendix A — PPO Hyperparameters

Table 5-4 reproduction

learning_rate	3.0e-4	**total_episodes**	10,000
gae_lambda	0.95	**rollout_per_episode**	32
clip_ratio	0.2	**update_epochs**	4
value_coef	0.5	**minibatch_size**	8
entropy_coef	0.01	**gamma**	0.99
max_grad_norm	0.5	**seeds**	42, 123, 999

Appendix B — Case Studies CS-1 ~ CS-7 요약

Qualitative case summaries

CS-1	**Simple 정책 수렴**	세 정책 모두 F1=1.0 (최재원 교수 소속 학과)
CS-2	**Multi-hop 부분 회수**	R-DWA/L-DWA 동일 1/2 엔티티 , Oracle 2/2
CS-3	**Conditional 개선과 한계**	개별 실패지만 유형 집계 +36.7% (L-DWA > Oracle)
CS-4	**Faithfulness 2-branch**	Sentence 1.0 (과대) vs List 0.5 (환각 노출)
CS-5	**Retrieval 한계**	Oracle 조차 12 개 중 2 개만 — 컨텍스트 상한
CS-6	**교차 도메인 퇴행**	영어 질의 → density 0 → Vector-only 이하
CS-7	**List 프롬프트 효과**	F1_strict 0.137 → 0.529 (×3.86), 평균 latency −50%